FIAP

TECNÓLOGO EM INTELIGÊNCIA ARTIFICIAL

Bernardo Braga Perobeli

Felipe Stefani Honorato

Igor Paixão Sarak

Lucca Phelipe Masini

Luiz Henrique Poss

Observabilidade do endpoint de sensores da Forzy

Checkpoint integrado de Governança em IA e Front end

2026

Bernardo Braga Perobeli - RM 562468

Felipe Stefani Honorato - RM 563380

Igor Paixão Sarak - RM 563726

Lucca Phelipe Masini - RM 564121

Luiz Henrique Poss - RM 562177

Observabilidade do endpoint de sensores da Forzy

Trabalho apresentado à FIAP, no curso de Tecnólogo em Inteligência Artificial, para o checkpoint integrado das disciplinas de Governança em IA e Front-end. O estudo define e verifica um contrato de observabilidade para leitura atual e histórico de sensores da solução Forzy Digital Twin.

2026

RESUMO

Este trabalho define e valida um contrato de observabilidade para leitura atual e histórico de sensores no contexto da solução Forzy Digital Twin. A implementação utiliza FastAPI, registro persistente em SQLite e interface Streamlit com consumo por requests. O contrato contempla identificadores de chamada e sessão, funcionalidade, timestamp UTC, status HTTP, latência, quantidade retornada e idade do dado. São estabelecidos indicadores com fórmulas, metas iniciais, baselines, visualizações e procedimentos de resposta. A validação por HTTP local empregou três cenários independentes: 200 chamadas normais, quatro chamadas com falhas induzidas e 100 leituras com atraso de aquisição simulado. O cenário normal apresentou contexto e freshness completos, sem erros HTTP; o cenário de atraso manteve respostas rápidas enquanto violou o limiar de atualidade. Os resultados demonstram que desempenho de processamento e qualidade temporal são dimensões diferentes. O estudo também identifica limitações de identidade sem autenticação, perda de registros, tamanho de amostra e uso de um provider demonstrativo. A solução disponibiliza evidências brutas e testes para apoiar a auditoria do comportamento da API, sem confundir a demonstração com validação dos sensores físicos Forzy.

Palavras-chave: observabilidade; governança em IA; sensores; rastreabilidade; freshness.

LISTA DE ATIVOS

Ativo	Localização e função
API de sensores	backend/main.py - rotas e middleware
Provider demonstrativo	backend/provider.py - aquisição simulada
Contrato de métricas	backend/metrics.py - agregação e limiares
Persistência	backend/store.py e SQLite - registro das chamadas
Interface e consumo	app.py e client.py - Streamlit e requests
Evidências HTTP	evidencias/normal.json, falhas_induzidas.json e atraso_aquisicao.json
Testes	tests/ - oito testes automatizados
Demonstração	Demonstracao_Forzy.webm - gravação automatizada da interface

LISTA DE TABELAS

Tabela 1 - Resultados por cenário.
Tabela 2 - Baseline de latência por rota.
Tabela 3 - Responsabilidades e resposta operacional.

LISTA DE SIGLAS

API - Interface de programação de aplicações. HTTP - Protocolo de transferência de hipertexto. IA - Inteligência artificial. P50 - Percentil 50. P95 - Percentil 95. RM - Registro de matrícula. SLI - Indicador de nível de serviço. SLO - Objetivo de nível de serviço. UTC - Tempo Universal Coordenado.

SUMÁRIO

1 INTRODUÇÃO 5

2 FUNDAMENTAÇÃO E CRITÉRIOS 5

3 ARQUITETURA E IMPLEMENTAÇÃO 6

4 CONTRATO DE OBSERVABILIDADE 6

5 INDICADORES LIMIARES E AÇÕES 7

5.1 Latência de processamento 7

5.2 Taxa de erro HTTP 7

5.3 Completude e validade de contexto 8

5.4 Completude de freshness 8

5.5 Atualidade do dado 8

5.6 Completude de registro 8

6 MÉTODO DE VALIDAÇÃO 9

7 RESULTADOS E DISCUSSÃO 9

8 GOVERNANÇA E RESPOSTA OPERACIONAL 11

9 USO DE INTELIGÊNCIA ARTIFICIAL 11

10 CONCLUSÃO 12

REFERÊNCIAS 13

1 INTRODUÇÃO

A leitura de sensores de um digital twin precisa ser rastreável e temporalmente adequada ao uso. O retorno de um valor isolado não informa qual funcionalidade originou a chamada, se houve falha, quanto tempo o servidor levou ou se a aquisição está atrasada. Este trabalho organiza essas perguntas em um contrato de observabilidade aplicado às rotas de leitura atual e histórico da Forzy.

O objetivo geral é definir indicadores verificáveis e avaliar seu cumprimento com registros coletados pelo backend. Os objetivos específicos são instrumentar cada chamada, consumir os três endpoints no front-end, comparar cenários normais e de falha e estabelecer ações quando os limiares forem violados. O escopo não inclui autenticação, equipamentos, plantas ou avaliação de modelos de IA.

A demonstração utiliza um provider de sensores simulado. Portanto, as conclusões empíricas referem-se à instrumentação e à execução local da API; não comprovam a confiabilidade de uma aquisição física ou a integração com o provider original Forzy.

2 FUNDAMENTAÇÃO E CRITÉRIOS

A observabilidade permite investigar o comportamento de um sistema a partir dos sinais que ele emite. Logs, métricas e rastros fornecem perspectivas complementares (OPENTELEMETRY, s.d.). Neste checkpoint, os logs estruturados registram chamadas individuais e as métricas resumem suas propriedades. O identificador de requisição permite correlação local, mas não constitui um mecanismo completo de rastreamento distribuído.

Um indicador de nível de serviço descreve o que é medido; um objetivo de nível de serviço define uma meta. O processo de SRE recomenda formular objetivos relacionados à experiência de uso e refiná-los com evidências (THURGOOD et al., 2018). Este trabalho segue essa separação: as fórmulas são o contrato de medição; os números dos limiares são decisões iniciais do projeto, não valores impostos pelas fontes.

A latência de processamento representa rapidez da API. Freshness representa a idade da informação. Uma leitura antiga pode ser entregue em poucos milissegundos e continuar inadequada para uma decisão operacional. Completude de freshness indica se sua idade pôde ser avaliada; atualidade indica se a idade atende à meta. Nenhum desses indicadores comprova a exatidão física do sensor.

3 ARQUITETURA E IMPLEMENTAÇÃO

O fluxo é Streamlit para requests para FastAPI para provider de Sensores. O frontend mantém uma sessão pseudônima com session_state e envia X-Session-Id e X-Feature em cada consulta. O uso de middleware para tratar requisições e respostas é documentado pelo FastAPI (FASTAPI, s.d.); a persistência da sessão entre interações é documentada pelo Streamlit (STREAMLIT, s.d.). O middleware armazena um evento por chamada, inclusive erros, em SQLite.

GET /v1/sensores/{tag}/leitura-atual retorna tag, valor, unidade, severidade, origem e timestamp de aquisição. GET /v1/sensores/{tag}/historico retorna itens e quantidade, com limite entre 1 e 500. GET /v1/observabilidade retorna eventos, métricas agregadas, resultados por rota, avaliação dos limiares e saúde de persistência. O limite de eventos é de até 10 mil e a janela temporal pode variar de 1 a 1.440 minutos.

A consulta de observabilidade registra sua própria chamada somente depois de preparar a resposta; o evento aparece na próxima consulta. Essa rota fica fora dos indicadores de sensores. A aplicação identifica possibilidade de truncamento quando a quantidade retornada atinge o limite. Isso não garante uma janela completa: para auditoria integral, deve-se comparar a contagem externa com os eventos persistidos.

Na simulação, as leituras são produzidas ao iniciar o processo e suas datas não se renovam nas consultas. SENSOR_SIMULATION_AGE_SECONDS permite ensaiar aquisição atrasada. SENSOR_PROVIDER permite selecionar um módulo adaptador do provider real, mantendo SENSORS, current(tag) e history(tag, limit). Sem esse módulo original, a execução permanece demonstrativa.

4 CONTRATO DE OBSERVABILIDADE

Cada evento contém request_id único; timestamp do início da requisição em UTC; session_id; feature; validade dos limites de contexto; método HTTP; caminho; status_code; latency_ms; freshness_seconds; records_count. Sessão e funcionalidade são informações declaradas pelo cliente. Sessão vazia ou somente com espaços não satisfaz completude; feature deve corresponder à rota e os headers devem respeitar seus limites para satisfazer validade.

O tempo de processamento usa relógio monotônico e termina após preparar a resposta. Exclui escrita no banco e transporte HTTP. A idade do dado é calculada com relógio UTC como instante de avaliação menos timestamp de aquisição; no histórico, considera-se o item mais recente. Valores negativos indicam timestamp futuro e são excluídos da freshness válida. Em erros sem dados, idade e quantidade ficam nulas.

O esquema de leitura exige timestamp com fuso, valor numérico finito, tag, unidade, origem e severidade normal, alerta ou critico. Conteúdo fora do contrato produz HTTP 502; tag inexistente produz 404; parâmetros inválidos produzem 422. A persistência ocorre fora do loop assíncrono, e suas conexões são fechadas explicitamente.

Se a gravação falhar, a resposta de sensores continua disponível, mas recebe X-Observability-Status: unavailable; o processo incrementa um contador de falhas e registra o request_id no log operacional. O frontend sinaliza a perda. Esse comportamento preserva a consulta sem alegar rastreabilidade completa. O contador é volátil e reinicia com o processo; não substitui monitoramento externo.

5 INDICADORES LIMIARES E AÇÕES

A janela padrão é de 15 minutos. O baseline normal utiliza pelo menos 100 chamadas por rota, com parâmetros e concorrência documentados. Sem denominador, o indicador retorna null. A contagem mínima é uma regra didática de triagem, não uma garantia de representatividade estatística. Resultados por minuto servem à visualização e podem conter poucas observações; sua leitura não equivale à avaliação de um SLO de produção.

5.1 Latência de processamento

Ordenar as latências em milissegundos e selecionar a posição teto de 0,95n para P95; usar teto de 0,50n para P50. A avaliação deve ocorrer por rota, além do agregado.

Limiar e justificativa: P95 <= 500 ms. A meta reserva um orçamento inicial de processamento para uma consulta interativa; deve ser revista com o provider real, tamanho de histórico e condições de uso. Não representa tempo total da interface.

Visualização e resposta: Linha do P95 por minuto e tabela por rota. Em violação, o responsável pelo backend compara rota e tamanho do histórico, investiga I/O e provider e repete a mesma carga após correção.

5.2 Taxa de erro HTTP

100 × chamadas com status >= 400 / total de chamadas de sensores. Calcular também 4xx e 5xx separadamente.

Limiar e justificativa: Taxa total <= 1% em tráfego normal, correspondente ao objetivo inicial de pelo menos 99% de respostas sem erro HTTP. Falhas induzidas não compõem o baseline normal. Esse indicador não mede disponibilidade em períodos sem chamadas.

Visualização e resposta: Barras de 4xx e 5xx por rota. Para 4xx, corrigir tags e parâmetros no cliente; para 5xx, investigar backend e provider. Confirmar a recuperação em nova janela comparável.

5.3 Completude e validade de contexto

Completude = 100 × chamadas com sessão e funcionalidade preenchidas / total. Validade = 100 × chamadas com sessão válida, funcionalidade correspondente e limites respeitados / total.

Limiar e justificativa: Meta 100% para ambos, pois o cliente controlado deve enviar contexto em toda consulta. Não aceitar preenchimento como prova de identidade ou autenticidade.

Visualização e resposta: Cartões, série de completude por minuto e registros filtrados. O responsável pelo frontend corrige os headers e retesta as três funcionalidades. Qualquer falha deixa a correlação de uso incompleta.

5.4 Completude de freshness

100 × respostas 200 com idade numérica finita e não negativa / total de respostas 200 de sensores.

Limiar e justificativa: Meta 100%. Uma leitura usada em monitoramento precisa trazer um timestamp que permita avaliar sua idade. Data futura é invalidade temporal, não sinal de dado recente.

Visualização e resposta: Cartão e linha da completude por minuto. O responsável pelo provider verifica aquisição, fuso e relógios. Corrigir timestamps antes de interpretar atualidade.

5.5 Atualidade do dado

100 × idades válidas <= 120 s / total de idades válidas; acompanhar também P95 da idade em segundos.

Limiar e justificativa: Meta >= 95% dentro de 120 s e P95 de idade <= 120 s. O limite inicial pressupõe aquisição a cada 60 s mais um intervalo de tolerância. Essa cadência é a da simulação e precisa ser confirmada no provider real.

Visualização e resposta: Linha do P95 da idade e aviso no frontend. Ao exceder 120 s, sinalizar atraso e verificar a aquisição. Se continuar acima do limiar após um ciclo adicional de 60 s, escalar ao responsável pelo provider; após correção, coletar nova janela.

5.6 Completude de registro

100 × eventos de sensores persistidos / chamadas de sensores emitidas no roteiro externo, após todas as respostas terminarem.

Limiar e justificativa: Meta 100%. Uma taxa calculada somente a partir do próprio log não detecta os eventos que foram perdidos. Comparar contagens externas e IDs de requisição.

Visualização e resposta: Barras de emitidos versus registrados e contador de falhas. Investigar disco, permissões e banco; marcar a evidência como incompleta e repetir a coleta depois da recuperação.

Os gráficos e resultados de limiar da interface são atualizados ao consultar. Não há notificação automática em segundo plano, nem sonda externa de disponibilidade. A completude de registro é verificada no roteiro de validação e não pode ser deduzida apenas do endpoint. Limiares de severidade de temperatura e vibração são ilustrativos, sem aprovação de engenharia de domínio.

6 MÉTODO DE VALIDAÇÃO

A validação ocorreu em 2 de outubro de 2026, com Python 3.12.14, FastAPI 0.142.2, Uvicorn 0.54.0, Streamlit 1.64.0 e requests 2.34.2. O cliente chamou a API por HTTP local, com concorrência 1 e histórico limitado a 30 leituras. Os cenários utilizaram bancos separados, evitando mistura entre tráfego normal e falhas intencionais. As evidências preservam timestamps UTC, parâmetros, eventos e agregados.

O cenário normal emitiu 200 chamadas, sendo 100 para leitura atual e 100 para histórico. O cenário de falhas emitiu quatro chamadas: tag inexistente, limite inválido, ausência de headers e funcionalidade incorreta. O cenário de atraso emitiu 100 consultas de leitura atual com aquisição simulada 300 segundos antes do início. A interface foi testada com AppTest consumindo a API HTTP em execução, inclusive o aviso de atraso.

Oito testes automatizados verificaram rotas, status, contexto ausente, falha interna, persistência, janela temporal, percentis por rota, timestamp futuro, esquema inválido, dado antigo e indisponibilidade do banco. A execução inclui múltiplas asserções por teste. O vídeo automatizado registra as telas da aplicação; não constitui uma apresentação oral dos integrantes.

7 RESULTADOS E DISCUSSÃO

Tabela 1 - Resultados por cenário

Indicador	Normal	Falhas induzidas	Aquisição atrasada
Chamadas	200	4	100
P95 processamento ms	4.396	3.401	3.121
Erros HTTP %	0.0	50.0	0.0
Contexto completo %	100.0	75.0	100.0
Contexto válido %	100.0	50.0	100.0

Indicador	Normal	Falhas induzidas	Aquisição atrasada
Freshness completa %	100.0	100.0	100.0
Dados em até 120 s %	100.0	100.0	0.0
P95 idade segundos	11.701	6.367	303.837

Fonte: registros da validação HTTP local de 2 out. 2026. Dados de sensores simulados.

Na amostra normal, os limiares iniciais foram atendidos: não houve erros HTTP, o contexto estava completo e válido, e todas as idades ficaram dentro de 120 segundos. Foram persistidas as 200 chamadas de sensores emitidas, produzindo completude de registro de 100% nesse roteiro controlado. Isso não prova ausência de perdas em outra carga ou ambiente.

Tabela 2 - Baseline de latência por rota

Rota	Chamadas	P50 ms	P95 ms
historico	100	2.100	4.551
leitura-atual	100	1.620	3.026

Fonte: evidencias/normal.json.

O P95 de ida e volta medido pelo cliente HTTP foi 49.504 ms. Esse resultado incorpora custos que a latência interna exclui e não deve ser substituído pelo P95 do middleware. As distribuições não são subtraídas entre si para estimar componentes, pois seus percentis podem corresponder a requisições diferentes.

No cenário de falhas, a taxa de erro HTTP de 50% decorre de dois erros esperados em quatro chamadas: 404 e 422. A completude de contexto de 75% e a validade de 50% demonstram que presença e correção semântica do header são critérios distintos. A amostra é pequena e foi construída para verificar detecção; não representa taxa de falha operacional. A ação adequada é corrigir tags, parâmetros e headers, e repetir o roteiro.

No cenário de atraso, o P95 de processamento foi 3.121 ms, mas o P95 da idade chegou a 303.837 s. Nenhuma leitura atendeu ao limite de 120 s. A freshness permaneceu completa porque a idade era calculável; a atualidade foi violada porque o dado era antigo. O contraste demonstra por que acompanhar apenas rapidez ou sucesso HTTP não basta para governança de sensores.

Os resultados têm validade restrita: o provider é demonstrativo, a concorrência foi unitária, a coleta foi curta e o serviço foi executado localmente. Não foram testados sensores físicos, rede externa, aquisição contínua, distribuição de carga ou um modelo de IA. Uma evolução deve repetir a coleta com o provider original, documentar sua cadência e incluir

condições operacionais representativas.

8 GOVERNANÇA E RESPOSTA OPERACIONAL

Tabela 3 - Responsabilidades e resposta operacional

Responsável	Sinal	Resposta e encerramento
Backend	Latência ou 5xx	Investigar rota, I/O e provider; repetir carga e documentar recuperação.
Frontend	Contexto incompleto ou inválido	Corrigir headers e parâmetros; validar todas as funcionalidades.
Provider de sensores	Dados antigos ou timestamp inválido	Verificar aquisição e relógios; reavaliar depois de um ciclo de aquisição.
Responsável pela evidência	Perda de registros ou janela truncada	Marcar amostra incompleta; recuperar banco e repetir coleta com contagem externa.
Grupo	Meta inadequada ao uso real	Revisar contrato, registrar justificativa e versionar mudança de limiar.

A resposta a uma violação deve registrar indicador, janela, valor, limiar, request_ids relevantes, responsável, hipótese, intervenção e resultado de verificação. Uma correção só encerra a ocorrência após nova coleta comparável. Evitar elevar uma meta apenas para transformar uma violação em aparente sucesso.

A sessão declarada pelo cliente permite correlação, mas não identificação pessoal confiável. Sem autenticação, não há prova de autoria nem proteção contra consulta indevida ao endpoint de logs. Por isso, este protótipo é destinado à execução local de avaliação, conforme o escopo do checkpoint. Não se afirma que ele está pronto para publicação pública.

Não são registrados nomes, RM, IP, cookies ou tokens nas chamadas. A política proposta é conservar a evidência estritamente necessária até encerrar a avaliação acadêmica e realizar limpeza controlada após sua conclusão. Não há exclusão automática nem controle de acesso implementado. Essas capacidades ficam para uma evolução compatível com o escopo da Sprint 4.

9 USO DE INTELIGÊNCIA ARTIFICIAL

Foi utilizado Codex, assistente de IA generativa, para apoiar pesquisa documental, redação, geração e revisão do código, preparação dos testes, análise das evidências e elaboração da conclusão. O uso também abrange a automação da demonstração em navegador. As fontes consultadas são identificadas nas referências, e as medições são derivadas de arquivos de evidência preservados no projeto.

O texto, inclusive a conclusão, foi elaborado com assistência de IA. Os integrantes são responsáveis pela conferência das fontes, pela compreensão do código e pela revisão das interpretações antes da entrega. Os registros anexados identificam o uso de sensores simulados e o ambiente de validação, permitindo distinguir medições do protótipo de afirmações sobre a operação real.

10 CONCLUSÃO

A implementação demonstra que um contrato de observabilidade pode transformar chamadas de sensores em evidências verificáveis. Identificadores, contexto, códigos HTTP e tempos registrados permitem localizar problemas no cliente, no processamento e na qualidade temporal da informação. A análise das amostras mostrou que completude, validade e atualidade precisam ser avaliadas separadamente.

Nas 200 chamadas normais, os indicadores atenderam às metas iniciais dentro das condições locais de teste. As falhas induzidas foram identificadas nos registros, e o cenário de aquisição atrasada revelou uma limitação que o sucesso HTTP esconderia: apesar do P95 de processamento de 3.121 ms, o P95 da idade foi 303.837 segundos. A resposta rápida não corrigiu a aquisição antiga. Esse resultado sustenta a necessidade de acompanhar freshness junto à latência.

O contrato também estabelece consequências práticas para violações: corrigir contexto no frontend, investigar erros e processamento no backend, verificar aquisição no provider e interromper alegações de rastreabilidade completa diante de perda de registros. Assim, os indicadores deixam de ser apenas números e passam a orientar investigação e verificação da recuperação.

O próximo passo técnico é integrar o provider original Forzy e repetir o baseline com sua cadência de aquisição e condições de uso. A simulação e os testes locais comprovam a coerência do protótipo, mas não autorizam extrapolar confiabilidade para sensores físicos ou produção. A contribuição do trabalho é oferecer um processo explícito de medição, interpretação e resposta dentro do escopo do checkpoint.

REFERÊNCIAS

FASTAPI. Middleware. Disponível em: https://fastapi.tiangolo.com/tutorial/middleware/. Acesso em: 2 out. 2026.

GOVERNANÇA EM IA E FRONT-END. Checkpoint integrado de observabilidade de um endpoint de IA Sensor Monitoring API. Enunciado disponibilizado no arquivo Checkpoint_Governanca_Frontend 1.docx. 2026.

OPENTELEMETRY. Observability primer. Disponível em: https://opentelemetry.io/docs/concepts/observability-primer/. Acesso em: 2 out. 2026.

STREAMLIT. Session State. Disponível em: https://docs.streamlit.io/develop/api-reference/caching-and-state/st.session_state. Acesso em: 2 out. 2026.

THURGOOD, Steven et al. Implementing SLOs. In: BEYER, Betsy et al. (org.). The Site Reliability Workbook. 2018. Disponível em: https://sre.google/workbook/implementing-slos/. Acesso em: 2 out. 2026.

UNIVERSIDADE FEDERAL DE SÃO JOÃO DEL REI. Manual de normalização 2025. Disponível em: https://dibib.ufsj.edu.br/wordpress/wp-content/uploads/Manual-de-Normalizacao-2025.pdf. Acesso em: 2 out. 2026.